

LSTM neuronske mreže

primena nad problemom sekvencijalnog učenja

Nevena Soldat i Milena Kurtić

Matematički fakultet, Univerzitet u Beogradu

22. april 2020.

Pregled

- Uvod
- Rekurentne neuronske mreže
- Problem generisanja teksta
- Rezultati
- Literatura

Uvod

Neuronske mreže:

- jedna od najprimenjenijih metoda mašinskog učenja
- različite vrste (potpuno povezane, konvolutivne, rekurentne...)
- simulacija velike količine povezanih nervnih ćelija


Opis rada

- Implementacija LSTM neuronske mreže i primena na problem generisanja teksta
- Baza - opisi filmova
- Cilj: za ulaznu sekvencu reči pretpostaviti koje će biti naredne

Rekurentne neuronske mreže

- Rekurentne neuronske mreže (eng. Recurrent Neural Network - RNN) - arhitektura neuronskih mreža specijalizovana za obradu sekvencijalnih podataka
- Sekvence nameću važnost redosleda zapažanja podataka
- Elementi ulazne sekvence se obrađuju u koracima
- Mreža ima skriveno stanje koje akumulira informaciju o elementima sekvence obrađenim u prethodnim koracima

Arhitektura RNN




Problemi sa RNN

- 1 Koordinate gradijenta eksplodiraju ili nestanu prilikom izračunavanja gradijenta propagacijom u prošlost zbog velikog broja množenja
- 2 Dugoročno čuvanje relevantnih informacija nije moguće - doprinos starijih ulaza se brzo gubi pod uticajem novih.

LSTM neuronske mreže

- podvrsta rekurentnih neuronskih mreža
- rešavaju oba prethodno navedena problema
- pamćenje dugih sekvenci je praktično njihovo podrazumevano ponašanje
- osnovna ideja - postojanje ćelije koja čuva skriveno stanje, uz kontrolu pisanja, čitanja i zaboravljanja

Arhitektura LSTM



Problem generisanja teksta

- Generisanje teksta ima brojne primene, kao što su automatsko prevođenje jezika, sumarizacija teksta, generisanje opisa...
- Naš cilj je da dobijemo kratak opis filma, uz zadavanje ulaznih reči.
- Faze rešavanja:
 - 1 Preprocesiranje teksta
 - 2 Kreiranje i treniranje modela
 - 3 Rezultati

Preprocesiranje teksta

- Neuronske mreže ne mogu da rade sa sirovim podacima, odnosno tekstom
- Kodiramo reči kao brojeve uz pomoć Tokenizer API-a
- Proces tokenizacije:
 - konvertovanje svih slova u mala
 - uklanjanje belina
 - uklanjanje znakova interpunkcije
 - ...
- **Token** - jedna reč kodirana kao broj

Preprocesiranje teksta


- maksimalan broj reči - 10 000
- rečnik sa odgovarajućim vrednostima - reč : broj
- inverzni rečnik za dekodiranje - broj : reč

```
from keras.preprocessing.text import Tokenizer  
  
max_words = 10000  
tokenizer = Tokenizer(num_words = max_words)  
tokenizer.fit_on_texts(sample)  
  
reverse_word_map = dict(map(reversed, tokenizer.word_index.items()))
```

Kreiranje ulaza i izlaza

- Biramo nasumično 100 filmova
- Uzimamo po 200 reči iz svakog opisa
- Sve opise spajamo u jedan korpus
- Ulaz - sekvenca od 20 reči
- Izlaz - naredna reč

Primer



Arhitektura mreže

Mreža za rešavanje problema sastoji se od narednih slojeva:


- 1 Ulazni sloj
- 2 Prvi LSTM sloj
- 3 Sloj izbacivanja
- 4 Drugi LSTM sloj
- 5 Izlazni sloj

Arhitektura mreže

```
model = Sequential()  
model.add(Embedding(vocab_size+1, 32, input_length = trainX.shape[1]))  
model.add(LSTM(200, return_sequences=True))  
model.add(Dropout(0.2))  
model.add(LSTM(200))  
model.add(Dense(trainy.shape[1], activation = 'softmax'))
```



Rezultati: Brzina konvergencije

- rezultat kroz 20 epoha




Rezultati: Brzina konvergencije

- rezultat kroz 50 epoha



Rezultati: Brzina konvergencije

- rezultat kroz 100 epoha



Rezultati: Preciznost i greška

Broj epoha	Broj neurona	Preciznost	Gubitak
20	100	27.38	5.11
50	100	38.18	4.27
100	100	43.88	3.88
20	200	27.80	4.83
50	200	38.78	3.96

Rezultati: Izlaz

■ rezultat kroz 20 epoha

```
print(generate_words("The movie", 50, model))
```

The Movie And A Family And A Family And Is Has And Has And Has And Has And Has And Has And Has And Has And Has And Has And
Has And Has And Has And Has And Has And Has And Has And Has And Has And Has And Has And Has And

Rezultati: Izlaz

■ rezultat kroz 50 epoha

```
print(generate_words("The movie", 50, model))
```

The Movie And Harford Phil Wheeler In Paradise Overhearing Reptiles The Fight Of A Local Woman And Has Been Forced To Be A Wife Technician And His Friend Who Is An Mother Who Is An Illegitimate Family Jr A J And Thief A Wife Technician And Says And Says And Tells By

Rezultati: Izlaz

■ rezultat kroz 100 epoha

```
print(generate_words("The movie", 50, model))
```

The Movie And Everyone But Is Kidnapped To Be A Young Woman Who Is An Matador And Uses His Contented Hack Benet Br
eaks A Merry Strife That He Has Been Forced To Be Changed By Ghostface In The Family But Been Slaughtered By His S
traight Priest Who Is An Dominates Who Is

Dalji razvoj

- povećanje broja epoha na više stotina
- eksperimentisanje sa brojem neurona i brojem slojeva mreže
- korišćenje GPU
- smanjenje broja ciljnih reči
- ...

HVALA NA PAŽNJI!